

PRÉDICTION NIR DE LA COMPOSITION DU MAÏS

De la calibration sur un spectromètre au transfert entre instruments

Étude chimiométrique & Machine Learning sur le jeu de données Corn (Cargill / Eigenvector Research)

Laté LAWSON

Chimiométrie & Machine Learning appliqués à la spectroscopie proche infrarouge





Pourquoi le NIR, et pourquoi ce projet ?

La spectroscopie proche infrarouge (NIR) permet d'estimer en quelques secondes la composition d'un produit agricole, sans réactif ni destruction de l'échantillon, à partir de la façon dont il absorbe la lumière.



Rapide : Résultat en quelques secondes, sans laboratoire de chimie humide



Non destructif : L'échantillon reste intact après la mesure



Multi-propriétés : Humidité, huile, protéine, amidon en une seule mesure



Le vrai obstacle industriel

Un modèle calibré sur un spectromètre donné devient souvent inutilisable sur un autre appareil du même modèle, ou sur le même appareil après dérive dans le temps, alors que rien n'a changé dans les échantillons mesurés.

C'est le problème connu sous le nom de calibration transfer, l'un des freins industriels les plus documentés de la chimiométrie NIR, et le fil conducteur de cette étude.



Le jeu de données : le benchmark Corn



80

échantillons de maïs



3

spectromètres (m5, mp5, mp6)



4



propriétés de référence



700

longueurs d'onde (1100-2498 nm)

Chaque échantillon physique est mesuré sur les trois instruments : ce couplage permet d'étudier le transfert de calibration de façon rigoureuse, en isolant l'effet instrument de tout effet d'échantillon.





Démarche méthodologique




Chaque étape est validée par des tests automatisés et exécutée de bout en bout dans des notebooks reproductibles.



Diagnostic spectral : additif ou multiplicatif ?


- 1 Un effet additif décale le spectre, indépendamment de son niveau : bandes parallèles.
- 2 Un effet multiplicatif dilate le spectre autour de sa moyenne : dispersion en cône.
- 3 Sur ce jeu de données : l'effet multiplicatif domine 1100-1450 nm, l'effet additif domine au-delà.
- 4 **Choix retenu : Detrend, appliqué sur 1450-2500 nm, corrige la tendance de fond sans toucher l'échelle.**



Spectres bruts (gauche) et après Detrend (droite) : motifs d'absorption nets après correction



Performance sur un instrument : ça marche



RPD jusqu'à 20,5

pour l'humidité, un modèle de qualité
contrôle industrielle (RPD > 5)


Validation : leave-one-out imbriquée

chaque prédiction évaluée sur un
échantillon jamais vu, ni pour
l'entraînement ni pour le réglage du modèle

Prétraitement optimal par propriété : Moisture (brut), Oil et Starch (dérivée 2), Protein (dérivée 1), identifié par comparaison empirique de 7 variantes.




Moins de variables, plus de précision



Score VIP le long du spectre (Protein) : identifie les longueurs d'onde les plus contributives

L'Elastic Net réduit le spectre à 51-124 longueurs d'onde selon la propriété (contre 525-700 pour la PLS), en ne gardant que les zones réellement informatives.




Près de 2x plus précis pour Protein, à variables très réduites



La régularisation linéaire simple gagne

RMSE par propriété : PLSR vs Ridge



SVR, forêt aléatoire, gradient boosting : testés et systématiquement moins bons.

À 80 échantillons pour des centaines de variables corrélées, la flexibilité d'un modèle non linéaire ajoute de la variance, pas de la précision.




Le vrai défi : ça s'effondre en changeant d'instrument

R^2 jusqu'à

-16

quand un modèle calibré sur un instrument est appliqué tel quel à un autre, sans aucune correction, pire qu'une simple moyenne constante.




Deux spectromètres, même modèle apparent, ne produisent jamais des spectres rigoureusement superposables : différences d'alignement optique, de détecteur, de source lumineuse.



Restaurer la performance : trois méthodes comparées

RMSE par méthode de transfert (moyenne mp5/mp6)



Résultat inattendu : la méthode la plus simple (2 paramètres) devance la référence Direct Standardization pour 3 propriétés sur 4.



Trois enseignements clés



Une validation qui ne triche pas

La leave-one-out imbriquée évite l'optimisme classique quand on compare des prétraitements sur peu d'échantillons.



Le linéaire régularisé gagne

À 80 échantillons, Ridge et Elastic Net dépassent la PLS et tous les modèles non linéaires testés.



La simplicité l'emporte au transfert

La correction pente-biais, la plus simple des trois testées, devance la référence pour 3 propriétés sur 4.

Un travail reproductible, pas seulement des chiffres



80 tests unitaires : valident automatiquement chargement, prétraitement, validation croisée et modèles



3 notebooks exécutés : de bout en bout, figures et tableaux régénérés à chaque exécution



Démo Streamlit : exploration interactive des spectres et ajustement de modèle en quelques clics

Merci

Laté LAWSON

latejeanjacques@gmail.com