

---

# **Prédiction de la composition du maïs par spectroscopie proche infrarouge : de la calibration intra-instrument au transfert entre spectromètres**

---

Étude chimiométrique et machine learning

*Laté LAWSON*

## Résumé

La spectroscopie proche infrarouge (NIR) permet de mesurer la teneur en eau, huile, protéine et amidon d'un grain de maïs en quelques secondes, sans réactif ni destruction de l'échantillon. Le principal frein à son usage industriel n'est pas la précision du modèle sur l'instrument qui a servi à le calibrer, mais sa capacité à rester valable quand on change de spectromètre. Ce travail construit, sur le jeu de données public Corn (Cargill / Eigenvector Research, 80 échantillons, trois spectromètres), une chaîne complète : diagnostic de la déformation spectrale, choix d'un prétraitement, régression PLS validée par validation croisée leave-one-out imbriquée, sélection de variables, comparaison à des modèles de machine learning, puis transfert de calibration entre instruments par trois méthodes (Direct Standardization, Piecewise DS, et une correction pente/biais plus simple). Le modèle calibré sur un instrument s'effondre presque partout quand on l'applique tel quel à un autre appareil ( $R^2$  jusqu'à  $-16$ ), ce qui confirme que le transfert de calibration est un problème réel. Une fois corrigé, il retrouve une performance exploitable pour les quatre propriétés. Résultat plus inattendu : la méthode de correction la plus simple, qui ajuste seulement la prédiction finale plutôt que le spectre lui-même, devance la méthode de référence (Direct Standardization) sur trois propriétés sur quatre.

## Introduction

La spectroscopie proche infrarouge est utilisée depuis les années 1980 dans l'industrie agroalimentaire pour estimer rapidement la composition d'un produit (humidité, matière grasse, protéines, sucres) à partir de la façon dont il absorbe la lumière entre 700 et 2500 nm environ. Le signal mesuré ne donne pas directement ces valeurs : il faut construire un modèle statistique qui relie le spectre à une mesure de référence obtenue par une méthode d'analyse classique, sur un ensemble d'échantillons connus. Ce modèle, souvent une régression PLS (*Partial Least Squares*), est ensuite appliqué aux mesures futures.

Le problème pratique qui limite le déploiement de cette approche n'est généralement pas la qualité du modèle sur l'appareil qui a servi à le construire, mais sa capacité à produire des résultats corrects sur un autre appareil du même modèle, ou sur le même appareil après une dérive dans le temps. Deux spectromètres identiques en apparence ne produisent jamais des spectres rigoureusement superposables : différences d'alignement optique, de détecteur, de source lumineuse. Un modèle appris sur l'un peut devenir inutilisable sur l'autre, alors que rien n'a changé dans la composition des échantillons mesurés. Ce phénomène, connu sous le nom de « *calibration transfer* », est l'un des obstacles industriels les plus documentés de la chimiométrie NIR.

Ce projet part du jeu de données Corn, un benchmark public conçu précisément pour étudier cette question : 80 échantillons de maïs, chacun mesuré sur trois spectromètres différents, avec les quatre propriétés de référence mesurées une seule fois par échantillon (humidité, huile, protéine, amidon). L'objectif est double. D'abord construire et valider rigoureusement un modèle de prédiction sur un seul instrument, en évitant les pièges classiques de sur-optimisme. Ensuite mesurer très concrètement ce qui se passe quand ce modèle est appliqué à un autre instrument, et comparer plusieurs méthodes de correction pour restaurer sa performance.

L'ensemble du travail (chargement des données, prétraitement, modélisation, transfert de calibration) est implémenté dans un dépôt de code testé (89 tests unitaires) et exécuté de bout en bout dans trois notebooks.

## Données

Le jeu de données provient de Cargill, distribué avec permission par Eigenvector Research comme référence pour les méthodes de transfert de calibration (Eigenvector Research, 1999). Il contient :

- des spectres d'absorbance pour 80 échantillons de maïs, mesurés sur trois spectromètres NIR nommés m5, mp5 et mp6, de 1100 à 2498 nm par pas de 2 nm (700 longueurs d'onde) ;
- pour chaque échantillon, quatre propriétés de référence mesurées par chimie humide : la teneur en eau (Moisture), en huile (Oil), en protéines (Protein) et en amidon (Starch) ;
- pour chaque instrument, quelques spectres de standards de calibration en verre optique (NBS), utilisés habituellement comme référence physique indépendante de tout échantillon de maïs.

Le point essentiel de ce jeu de données est que chaque échantillon physique est mesuré sur les trois instruments : la ligne 12 du tableau m5spec, la ligne 12 de mp5spec et la ligne 12 de mp6spec correspondent au même grain de maïs. Ce couplage est ce qui permet d'étudier le transfert de calibration de façon rigoureuse : sans lui, on ne pourrait pas distinguer un vrai effet instrument d'une simple différence entre deux populations d'échantillons.

## Méthodes

### Protocole de validation

Avec seulement 80 échantillons, la façon de mesurer la performance d'un modèle compte presque autant que le modèle lui-même. Un piège classique en chimiométrie comme en apprentissage automatique consiste à utiliser la même validation croisée pour deux choses à la fois : choisir un réglage du modèle (ici, le nombre de composantes latentes de la régression PLS) et estimer sa performance finale. Quand ces deux usages se confondent, l'estimation obtenue est optimiste, parfois nettement, parce que le réglage choisi est implicitement celui qui colle le mieux aux données de validation elles-mêmes (Varma & Simon, 2006). Ce risque est d'autant plus réel ici que le nombre d'échantillons est faible et que le nombre de variables (jusqu'à 700 longueurs d'onde) est très supérieur au nombre d'échantillons.

Pour l'éviter, ce projet utilise une validation croisée **leave-one-out imbriquée** : chacun des 80 échantillons est laissé de côté à tour de rôle, et pour chaque échantillon laissé de côté, le nombre de composantes PLS est choisi par une validation croisée interne effectuée uniquement sur les 79 échantillons restants. L'échantillon mis de côté n'intervient donc jamais dans le choix du réglage qui le concerne ; seule sa prédiction finale, une fois le modèle figé, compte dans le résultat. Cette architecture à deux niveaux, parfois appelée double validation croisée, est décrite spécifiquement pour la régression PLS par Filzmoser, Liebmann et Varmuza (2009), qui l'implémentent sous le nom `mvr_dev` dans le paquet R `chemometrics`. Le nombre de composantes testées est plafonné à 10, à la fois par une règle empirique courante en chimiométrie (au moins une dizaine d'échantillons par dimension du modèle) et parce que ce plafond correspond à celui utilisé par une autre équipe ayant publié une baseline PLSR sur ce même jeu de données (Catalas & Tutuncu, 2023), ce qui permet une comparaison directe.

Chaque étape de prétraitement qui apprend un paramètre à partir des données (une moyenne pour le centrage, un spectre de référence pour la correction multiplicative de diffusion) est ajustée uniquement sur

le pli d'entraînement de chaque itération, jamais sur l'ensemble complet. Sans cette précaution, une partie de l'information du point laissé de côté fuiterait dans le prétraitement avant même d'atteindre le modèle.

## Prétraitement spectral

Un spectre NIR brut mélange deux types d'information : l'absorption chimique, qui nous intéresse, et des effets physiques de diffusion de la lumière par la surface du grain, qui n'ont rien à voir avec sa composition mais dominant souvent visuellement le signal. Ces effets physiques se manifestent de deux façons, qui appellent des corrections différentes. Un effet **additif** décale l'ensemble du spectre vers le haut ou vers le bas, indépendamment de sa valeur locale. Visuellement, les spectres de plusieurs échantillons apparaissent comme des courbes parallèles, décalées les unes par rapport aux autres. Un effet **multiplicatif** dilate ou compresse le spectre autour de sa moyenne, un peu comme si chaque échantillon avait sa propre échelle verticale. Visuellement, l'écart entre échantillons grandit avec le niveau du spectre plutôt que de rester constant.

Sur ce jeu de données, l'analyse exploratoire (détaillée dans les résultats) montre que ces deux effets ne se répartissent pas uniformément sur la plage spectrale : l'effet multiplicatif domine entre 1100 et 1450 nm, tandis que l'effet additif domine au-delà, entre 1450 et 2500 nm. Ce constat oriente le choix du prétraitement retenu comme point de départ : plutôt qu'une correction générique comme la SNV (*Standard Normal Variate*) ou la MSC (*Multiplicative Scatter Correction*, Geladi, MacDougall & Martens, 1985), qui corrigent à la fois l'effet additif et l'effet multiplicatif sur tout le spectre, ce travail retient le **Detrend** (Barnes, Dhanoa & Lister, 1989) appliqué uniquement sur la région où l'effet additif domine (1450-2500 nm). Le Detrend soustrait, pour chaque échantillon, la droite de régression de son spectre contre la longueur d'onde : il retire une tendance de fond linéaire sans toucher à l'échelle verticale, ce qui correspond exactement à la nature de l'effet identifié sur cette plage.

Ce choix est un point de départ justifié par le diagnostic, pas une conclusion définitive : une comparaison empirique complète, incluant les spectres bruts, un centrage simple, SNV, MSC, et les dérivées première et seconde de Savitzky-Golay (Savitzky & Golay, 1964), est menée séparément pour chaque propriété (voir Résultats, section Comparaison des prétraitements), avec le même protocole de validation croisée imbriquée.

## Régression PLS et sélection de variables

La régression PLS (Wold, Sjöström & Eriksson, 2001) est la méthode standard en chimiométrie pour ce type de problème : elle construit un petit nombre de combinaisons linéaires des longueurs d'onde (des « composantes latentes ») choisies pour maximiser leur covariance avec la propriété à prédire, plutôt que pour expliquer la variance des spectres eux-mêmes comme le ferait une ACP classique. Elle est bien adaptée aux données spectrales, où les centaines de longueurs d'onde sont fortement corrélées entre elles (des canaux voisins mesurent presque la même information), ce qu'une régression linéaire classique générerait mal.

Pour identifier quelles longueurs d'onde contribuent le plus à la prédiction, ce travail utilise le score VIP (*Variable Importance in Projection*, Wold, Johansson & Cocchi, 1993), qui résume la contribution de chaque variable à l'ensemble des composantes du modèle PLS ; une longueur d'onde avec un score VIP supérieur à 1 est considérée informative selon la convention usuelle. Ces zones sont comparées à celles

rapportées par une étude indépendante sur le même jeu de données (Fatemi, Singh & Kamruzzaman, 2022), qui combine le score VIP à un algorithme génétique pour affiner la sélection.

En complément de la sélection par score, ce travail teste aussi l'Elastic Net (Zou & Hastie, 2005), une régression linéaire régularisée qui combine une pénalité qui pousse certains coefficients exactement à zéro (sélection automatique de variables) et une pénalité qui répartit le poids entre variables corrélées. Cette combinaison a été pensée à l'origine pour des données où, comme ici, le nombre de variables dépasse largement le nombre d'échantillons et où ces variables sont redondantes entre elles.

## Comparaison à d'autres modèles

Pour vérifier si des modèles plus flexibles que la PLS apportent un gain, quatre méthodes complémentaires sont testées avec le même protocole de validation : la régression Ridge (une régression linéaire régularisée, plus simple que l'Elastic Net puisqu'elle ne met aucun coefficient à zéro), le SVR à noyau RBF (*Support Vector Regression*), la forêt aléatoire et le gradient boosting. Ces deux derniers sont des méthodes non linéaires, capables en principe de capturer des interactions complexes entre longueurs d'onde, mais aussi plus gourmandes en données pour être calibrées correctement.

## Transfert de calibration

Le cœur du problème étudié est le suivant : un modèle appris sur les spectres de l'instrument m5 reste-t-il valable si on l'applique aux spectres du même échantillon mesuré par mp5 ou mp6 ? Trois méthodes de correction sont comparées, chacune apprise sur un petit nombre d'échantillons dits « de transfert » sélectionnés par l'algorithme de Kennard-Stone (Kennard & Stone, 1969), qui choisit les échantillons les plus différents les uns des autres dans l'espace des spectres, afin de couvrir la variabilité du jeu de données avec le moins d'échantillons possible. C'est un critère pertinent ici puisque mesurer des échantillons de transfert a un coût dans la pratique industrielle.


La **Direct Standardization** (DS ; Wang, Veltkamp & Kowalski, 1991) apprend une transformation linéaire qui convertit un spectre mesuré sur l'instrument cible vers ce qu'il aurait été s'il avait été mesuré sur l'instrument de référence, à partir des spectres appariés des échantillons de transfert. La **Piecewise Direct Standardization** (PDS ; Wang, Veltkamp & Kowalski, 1991) raffine cette idée en apprenant une transformation locale à chaque longueur d'onde, à partir d'une petite fenêtre de longueurs d'onde voisines sur l'instrument cible, plutôt qu'une transformation globale. La troisième méthode, la correction **pentebiais** (*Slope and Bias Correction*, ou SBC), est nettement plus simple que les deux précédentes : au lieu de corriger le spectre avant de le passer dans le modèle, elle corrige directement la prédiction du modèle non corrigé, par une simple régression linéaire entre la prédiction obtenue sur l'instrument cible et la valeur vraie, ajustée sur les mêmes échantillons de transfert. Elle ne nécessite que deux paramètres (une pente et une ordonnée à l'origine), contre potentiellement plusieurs dizaines pour DS et PDS.

## Résultats

### Analyse exploratoire : identifier la déformation spectrale


La première étape a consisté à établir, avant tout choix de prétraitement, la nature exacte de la déformation présente dans les spectres. Le spectre moyen de l'instrument m5 (figure 1) montre une tendance croissante

avec la longueur d'onde. Cette tendance de fond n'est pas de nature chimique : elle vient de la diffusion de la lumière par la surface du grain. Les pics d'absorption liés à la composition chimique se superposent à cette tendance, mais restent difficiles à distinguer à l'œil sur le spectre brut.



*Figure 1 : Spectres bruts superposés par instrument*

Une ACP sur l'ensemble des spectres bruts, rassemblés sur les trois instruments, est dominée à 96 % par une seule composante (figure 2). Cette première composante reflète en bonne partie le décalage entre instruments plutôt que la composition des échantillons : l'écart moyen entre les spectres de m5 et mp5 pour un même échantillon est de 0,044 unité d'absorbance, et de 0,056 entre m5 et mp6.



*Figure 2 : Projection ACP des spectres bruts, colorée par instrument*

Pour caractériser précisément le type de déformation à corriger, chaque valeur spectrale est tracée en fonction de la valeur du spectre moyen à la même longueur d'onde (figure 3). Un effet purement additif produit un nuage de points en bandes parallèles à la diagonale, de largeur constante quel que soit le niveau ; un effet purement multiplicatif produit un nuage en forme de cône, dont la dispersion augmente avec le niveau. Sur l'ensemble du spectre, la forme du nuage ne permet pas de trancher clairement. En revanche, une fois la plage séparée en deux, le résultat devient net : entre 1100 et 1450 nm, le nuage s'évase nettement à partir d'un point resserré près de l'origine, ce qui signe un effet multiplicatif ; entre 1450 et 2500 nm en revanche, les points restent alignés en bandes de largeur constante, signe d'un effet additif.




Figure 3 : Diagnostic additif/multiplicatif, spectre vs spectre moyen (m5)

Une dernière vérification consiste à colorer les spectres bruts selon la valeur de chaque propriété à prédire (figure 4). Un dégradé de couleur net et ordonné le long du niveau global du spectre apparaît pour Moisture et pour Oil, ce qui indique que, pour ces deux propriétés, le niveau du spectre porte lui-même une partie du signal utile, pas seulement sa forme fine. Pour Protein et Starch, la coloration reste mélangée sans ordre apparent. Cette observation a une conséquence directe sur le choix du prétraitement : toute méthode qui retire le niveau global du spectre (comme SNV) retirera, avec lui, une partie du signal utile pour Moisture et Oil, alors qu'elle sera presque neutre pour Protein et Starch. C'est exactement ce que confirme la comparaison de prétraitements plus loin.






Figure 4 : Spectres bruts colorés par valeur de la propriété cible (m5)

Sur la base de ce diagnostic, le prétraitement retenu comme point de départ est le Detrend, appliqué après avoir restreint le spectre à la plage 1450-2500 nm (525 des 700 longueurs d'onde d'origine), là où l'effet additif domine. L'ordre des opérations importe : la coupure à 1450 nm doit précéder l'ajustement du Detrend, et non le suivre, car une régression par moindres carrés est influencée par tous les points qu'elle voit : ajuster la droite sur les 700 canaux puis ne garder que la région additive après coup laisserait la région multiplicative, pourtant exclue de l'analyse finale, fausser la droite de fond ajustée.




Figure 5 : Spectres bruts et spectres après Detrend (m5)



Après Detrend (figure 5), les spectres se superposent en une bande étroite, avec des motifs reconnaissables : une chute marquée vers 1850-1870 nm suivie d'un pic net vers 1920-1950 nm, qui correspond à la bande d'absorption de l'eau, puis des pics plus discrets vers 2100 et 2300-2320 nm, cohérents avec les bandes attribuées aux liaisons C-H et N-H rapportées dans la littérature (Samuel, Chinnu & Lakshmanan, 2015).

Deux réserves accompagnent ce choix. D'une part, la coupure à 1450 nm retire la bande d'absorption de l'eau qui s'étend en réalité un peu plus bas, vers 1450-1500 nm, ce qui devrait pénaliser spécifiquement Moisture. Une coupure à 1500 nm au lieu de 1450 nm serait une piste naturelle à tester, non encore explorée dans ce travail. D'autre part, la comparaison de prétraitements de la section suivante continue de tester la plage spectrale complète (1100-2500 nm) avec les sept variantes existantes, sans y inclure le Detrend : le choix fait ici reste un point de départ raisonné, pas une conclusion figée.

Une ACP menée sur les spectres après Detrend ne retient plus que trois composantes pour expliquer 95 % de la variance (86 %, 7 % et 3 % respectivement), contre plusieurs dizaines de composantes nécessaires sur les données brutes, un signe que le Detrend retire une source de variance dominante et non pertinente sans ajouter de bruit. Ces trois composantes restent chimiquement informatives : la première corrèle avec Moisture ( $r = 0,71$ ) et Oil ( $r = -0,36$ ), la troisième avec Moisture ( $r = 0,55$ ) et Oil ( $r = -0,53$ ), et la seconde avec Protein ( $r = -0,47$ ).

## Baseline PLSR intra-instrument

Le tableau 1 présente la performance d'une régression PLS sur l'instrument m5, spectres prétraités par Detrend, nombre de composantes choisi par validation croisée leave-one-out imbriquée (protocole décrit plus haut, plafond de 10 composantes).

**Tableau 1 : Performance PLSR intra-instrument (Detrend, LOO imbriqué)**

| Propriété | RMSE  | R <sup>2</sup> | RPD | Composantes<br>(mode, plage) |
|-----------|-------|----------------|-----|------------------------------|
| Moisture  | 0,049 | 0,983          | 7,7 | 9 (8-10)                     |
| Oil       | 0,061 | 0,880          | 2,9 | 10 (8-10)                    |
| Protein   | 0,090 | 0,967          | 5,5 | 9 (8-9)                      |
| Starch    | 0,265 | 0,894          | 3,1 | 7 (6-10)                     |

Le RPD (*Residual Predictive Deviation*, rapport entre l'écart-type de la propriété mesurée et l'erreur du modèle) dépasse 5 pour Moisture et Protein, ce qui correspond, selon les grilles usuelles en chimiométrie, à un modèle utilisable pour un contrôle qualité de routine. Il reste plus modeste pour Oil et Starch (autour de 3), ce qui indique un modèle correct.

Un résultat mérite d'être signalé explicitement plutôt que traité comme une anomalie : le prétraitement raw (spectres bruts, testé séparément dans la comparaison de prétraitements ci-dessous) obtient un meilleur résultat que Detrend pour Moisture (RMSE de 0,019 contre 0,049). Ce n'est pas surprenant compte tenu du diagnostic exploratoire : pour cette propriété précisément, une partie du signal utile réside dans le niveau global du spectre, et Detrend, en corrigeant la tendance de fond, retire une partie de ce signal en même temps que le bruit instrumental qu'il visait à corriger.

Le plafond de 10 composantes latentes appelle une justification, car la courbe de RMSE en validation croisée ne présente pas de coude net sur ce jeu de données : avec 525 longueurs d'onde fortement corrélées entre elles pour environ 80 échantillons, l'erreur continue de baisser lentement même après le point où l'ajout de composantes n'apporte plus d'information généralisable, un phénomène classique en présence de forte colinéarité. Le plafond retenu s'appuie donc sur deux repères externes plutôt que sur la courbe elle-même : une règle empirique courante recommandant au moins une dizaine d'échantillons d'entraînement par composante du modèle, et le plafond utilisé par Cataltas et Tutuncu (2023) dans leur propre étude PLSR sur ce jeu de données, ce qui permet la comparaison suivante.

## Comparaison des prétraitements

Sept variantes de prétraitement sont comparées avec le même protocole de validation, sur l'ensemble de la plage spectrale (1100-2500 nm) : spectres bruts, centrage simple, SNV, MSC, et les dérivées Savitzky-Golay (lissage, première dérivée, seconde dérivée).

**Tableau 2 : Meilleur prétraitement par propriété (comparaison à 7 variantes)**

| Propriété | Meilleur prétraitement | RMSE  | R <sup>2</sup> | RPD  |
|-----------|------------------------|-------|----------------|------|
| Moisture  | brut / centrage        | 0,019 | 0,998          | 20,5 |
| Oil       | dérivée seconde SG     | 0,030 | 0,971          | 5,9  |
| Protein   | dérivée première SG    | 0,093 | 0,965          | 5,4  |
| Starch    | dérivée seconde SG     | 0,228 | 0,922          | 3,6  |

Cataltas et Tutuncu (2023) rapportent, pour une régression PLS conventionnelle sur les spectres bruts de m5 (répartition 60 échantillons de calibration / 20 de test, jusqu'à 10 composantes), un RMSE de 0,0245 et un R<sup>2</sup> de 0,9957 pour Moisture. Notre propre résultat sur les spectres bruts, avec une validation croisée leave-one-out imbriquée plutôt qu'une répartition calibration/test unique, donne un RMSE de 0,019 et un R<sup>2</sup> de 0,998, du même ordre de grandeur malgré un protocole de validation différent, ce qui va dans le sens d'un signal réel plutôt que d'un effet propre à notre seul protocole.

Le résultat identique entre spectres bruts et centrage simple n'est pas une coïncidence : la régression PLS centre déjà ses données en interne, donc le centrage manuel n'apporte rien de plus ; ce résultat sert surtout de test de cohérence intégré à la comparaison. Plus instructif : SNV et MSC dégradent la performance pour chacune des quatre propriétés, le plus nettement pour Moisture, ce qui est cohérent avec le diagnostic exploratoire (ces méthodes retirent le niveau global du spectre, qui portait du signal utile pour cette propriété). Les dérivées de Savitzky-Golay forment la seule famille de prétraitements qui améliore systématiquement sur les spectres bruts pour Oil, Protein et Starch.

Face au point de départ Detrend retenu en amont (tableau 1), l'un des sept prétraitements testés ici fait nettement mieux pour Oil et pour Starch, d'un facteur proche de 2. Pour Protein en revanche, Detrend (RMSE 0,090) et la meilleure des sept variantes testées ici (dérivée première, RMSE 0,093) sont

pratiquement à égalité, un écart de l'ordre de 3 % à lire comme une observation plutôt que comme une raison de changer de prétraitement pour cette propriété.

## Sélection de variables et interprétabilité

Le score VIP calculé sur le meilleur prétraitement de chaque propriété permet d'identifier les longueurs d'onde qui contribuent le plus à chaque modèle (figure 6, exemple pour Protein). Comparées aux bandes rapportées comme informatives par Fatemi, Singh et Kamruzzaman (2022) pour les mêmes quatre propriétés sur ce même jeu de données, les longueurs d'onde retenues ici ( $VIP > 1$ ) recoupent entre 9 % et 23 % de leurs bandes selon la propriété. Ce recouvrement partiel, plutôt qu'une correspondance parfaite, s'explique par le fait que les deux approches répondent à des questions différentes : un seuil VIP simple ici, contre une sélection VIP combinée à un algorithme génétique dans leur étude, qui vise une sélection plus étroite et plus optimisée.




Figure 6 : Score VIP le long du spectre (Protein, m5)

Une alternative de sélection parcimonieuse, l'Elastic Net, est testée avec le même protocole de validation (tableau 3). Le résultat le plus notable de cette section est qu'Elastic Net dépasse nettement la régression PLS pour Protein (RMSE 0,047 contre 0,090, soit près de deux fois meilleur) et pour Starch (0,192 contre 0,228), tout en restant compétitif pour Oil et en perdant nettement pour Moisture.

Tableau 3 : Elastic Net vs meilleur PLSR par propriété

| Propriété | RMSE Elastic Net | RMSE PLSR | Longueurs d'onde retenues |
|-----------|------------------|-----------|---------------------------|
| Moisture  | 0,062            | 0,019     | 62                        |
| Oil       | 0,034            | 0,030     | 124                       |
| Protein   | 0,047            | 0,090     | 51                        |
| Starch    | 0,192            | 0,228     | 108                       |




Figure 7 : Coefficients Elastic Net retenus le long du spectre (Starch, m5)

Cet avantage pour Protein et Starch survit à la validation croisée leave-one-out imbriquée : ce n'est donc pas un artefact d'optimisme de validation à faible effectif, mais un effet qui se maintient une fois la sélection de variables elle-même soumise au même protocole rigoureux que le reste. Une explication plausible tient à la dimensionnalité effective retenue par chaque méthode : Elastic Net ne conserve que 51 à 124 longueurs d'onde selon la propriété, contre les 525 à 700 canaux vus par la PLS. Cette réduction aide quand le signal utile est concentré sur un nombre restreint de bandes d'absorption spécifiques (Protein, Starch), mais n'aide pas quand une partie du signal dépend du niveau global du spectre (Moisture), une information que la sélection de variables individuelles ne capture pas bien.

## Comparaison à des modèles de machine learning

Quatre modèles supplémentaires (Ridge, SVR à noyau RBF, forêt aléatoire, gradient boosting) sont comparés sur le meilleur prétraitement de chaque propriété, avec le même protocole de validation (tableau 4).

Tableau 4 : Meilleur modèle par propriété

| Propriété | Meilleur modèle | RMSE  | R <sup>2</sup> |
|-----------|-----------------|-------|----------------|
| Moisture  | Ridge           | 0,007 | 0,9997         |
| Oil       | Ridge           | 0,029 | 0,973          |
| Protein   | Ridge           | 0,030 | 0,996          |
| Starch    | Ridge           | 0,164 | 0,960          |

Sur les quatre propriétés, les modèles non linéaires (SVR, forêt aléatoire, gradient boosting) font systématiquement moins bien que les méthodes linéaires régularisées (PLS, Ridge). C'est une réponse directe à une question méthodologique centrale de ce travail : avec 80 échantillons seulement, la flexibilité supplémentaire d'un modèle non linéaire ne se traduit pas par un gain de précision : elle introduit au contraire une variance que les données ne permettent pas de contraindre suffisamment.

Ridge devance également la régression PLS sur les quatre propriétés, le plus nettement pour Protein (0,030 contre 0,090) et Starch (0,164 contre 0,228), un constat qui rejoint celui obtenu avec Elastic Net dans la section précédente : une régularisation linéaire simple semble mieux exploiter ce jeu de données que la PLS elle-même pour ces deux propriétés en particulier. Une piste naturelle pour prolonger ce travail serait d'essayer d'autres méthodes de sélection de variables pensées spécifiquement pour des données spectrales colinéaires, comme CovSel (Roger, Palagos, Bertrand & Fernandez-Ahumada, 2011), qui n'a pas été testée ici.

## Robustesse inter-instruments sans correction

La question centrale de ce travail est ensuite posée directement : que se passe-t-il quand le modèle appris sur m5 est appliqué, sans aucune correction, aux spectres de mp5 et mp6 pour le même échantillon (tableau 5) ?

**Tableau 5 : Performance sans correction, modèle 'm5' appliqué à 'mp5'/'mp6'**

| Propriété | RMSE intra-instrument (m5) | RMSE inter-instrument (mp5 / mp6) | R <sup>2</sup> inter-instrument (mp5 / mp6) |
|-----------|----------------------------|-----------------------------------|---------------------------------------------|
| Moisture  | 0,019                      | 1,46 / 1,55                       | -13,9 / -15,9                               |
| Oil       | 0,030                      | 0,28 / 0,18                       | -1,6 / -0,05                                |
| Protein   | 0,093                      | 0,80 / 0,95                       | -1,6 / -2,7                                 |
| Starch    | 0,228                      | 1,39 / 0,59                       | -1,9 / +0,49                                |

La performance s'effondre pour la quasi-totalité des combinaisons propriété/instrument : un R<sup>2</sup> négatif signifie que le modèle transféré fait pire qu'une prédiction constante égale à la moyenne. Deux exceptions partielles se dessinent : Oil sur mp6 reste proche de zéro, et Starch sur mp6 devient même légèrement positif (RPD de 1,40), mais restent bien en dessous du seuil usuel d'utilisabilité (RPD  $\geq 2$ ), ce qui ne remet pas en cause la conclusion générale. Ce résultat confirme que la très bonne performance intra-instrument observée pour Moisture (tableau 2) ne correspond pas à un signal chimique qui se transfère d'un appareil à l'autre : c'est justement ce que la section suivante cherche à corriger.

## Transfert de calibration

Trois méthodes de correction sont comparées, chacune apprise sur 25 échantillons de transfert sélectionnés par l'algorithme de Kennard-Stone par instrument, et évaluées sur les 55 échantillons restants, jamais utilisés pour ajuster la correction elle-même (tableau 6).


**Tableau 6 : Comparaison des méthodes de transfert de calibration**

| Propriété | Sans correction              | Direct Standardization                             | Piecewise DS                 | Correction pente-biais                             |
|-----------|------------------------------|----------------------------------------------------|------------------------------|----------------------------------------------------|
| Moisture  | RMSE 1,47<br>( $R^2 -18,5$ ) | <b>RMSE 0,17</b><br><b>(<math>R^2 0,75</math>)</b> | RMSE 0,29<br>( $R^2 0,16$ )  | RMSE 0,22<br>( $R^2 0,56$ )                        |
| Oil       | RMSE 0,24<br>( $R^2 -0,8$ )  | RMSE 0,12<br>( $R^2 0,56$ )                        | RMSE 0,70<br>( $R^2 -14,8$ ) | <b>RMSE 0,08</b><br><b>(<math>R^2 0,81</math>)</b> |
| Protein   | RMSE 0,87<br>( $R^2 -1,8$ )  | RMSE 0,18<br>( $R^2 0,89$ )                        | RMSE 0,55<br>( $R^2 -0,1$ )  | <b>RMSE 0,13</b><br><b>(<math>R^2 0,94</math>)</b> |
| Starch    | RMSE 0,97<br>( $R^2 -0,6$ )  | RMSE 0,42<br>( $R^2 0,73$ )                        | RMSE 1,64<br>( $R^2 -3,1$ )  | <b>RMSE 0,31</b><br><b>(<math>R^2 0,86</math>)</b> |


Les quatre nuages de points de la figure 8 illustrent ce résultat pour Protein : le nuage sans correction est dispersé loin de la diagonale (bonne prédiction = points alignés sur la diagonale), tandis que chacune des trois corrections resserre le nuage autour de la diagonale à des degrés divers.

**Figure 8 : Prédit vs mesuré pour Protein, avant et après correction (mp5)**


**Sans correction**




**Direct Standardization**



**Piecewise DS**



**Correction pente-biais**



Le résultat le plus inattendu de cette étude tient dans une comparaison simple : la correction pente-biais, qui est de loin la plus simple des trois méthodes testées (deux paramètres, contre une transformation spectrale complète pour les deux autres), devance la Direct Standardization pour Oil, Protein et Starch. Seule Moisture fait exception, où la Direct Standardization reste la meilleure des trois. La Piecewise DS, qui ajuste une transformation locale indépendante à chaque longueur d'onde à partir d'une fenêtre de onze points voisins, est systématiquement la moins bonne des trois méthodes, parfois pire que l'absence de correction.

Un même mécanisme explique ces deux observations. La Direct Standardization et la Piecewise DS corrigent le spectre lui-même avant de le passer dans le modèle ; avec seulement 25 échantillons de transfert, cette correction n'est jamais parfaite et laisse un résidu. Pour Oil, Protein et Starch, le meilleur prétraitement identifié plus haut est une dérivée de Savitzky-Golay, une opération qui amplifie justement les variations haute fréquence, y compris ce résidu de correction imparfaite. Cette amplification est particulièrement marquée pour la Piecewise DS, dont les fenêtres locales indépendantes ne sont contraintes à aucune cohérence entre longueurs d'onde voisines. Pour Moisture, dont le meilleur prétraitement est le spectre brut (sans dérivée), ce résidu n'est pas amplifié, et la correction plus riche de la Direct Standardization (qui peut mobiliser jusqu'à dix composantes PLS internes, contre deux paramètres

pour la correction pente-biais) reste alors avantageuse. La correction pente-biais, en intervenant après le modèle plutôt qu'avant, sur la prédiction finale plutôt que sur le spectre, ne souffre pas de cet effet d'amplification, ce qui explique son avantage précisément pour les propriétés dont le prétraitement optimal repose sur une dérivée.

Une tentative additionnelle a consisté à apprendre la Direct Standardization à partir des seuls standards de verre optique (NBS), sans utiliser aucun échantillon de maïs. Le résultat est nettement pire que l'absence de correction (RMSE jusqu'à 230). Deux limites se cumulent probablement : le nombre de standards appariés utilisables entre instruments est très faible (trois pour m5, quatre pour mp5 et mp6, un écart de comptage qui rend l'appariement utilisé, purement positionnel, non garanti), et la matrice optique du verre diffère fondamentalement de celle du maïs. Ce résultat est conservé ici par souci de transparence, non comme méthode recommandable.

## Discussion

Trois enseignements se dégagent de l'ensemble de ce travail. Le premier concerne la méthode de validation elle-même : sur un jeu de données de cette taille, la façon dont le nombre de composantes PLS est choisi change la conclusion qu'on peut tirer d'une comparaison de prétraitements. Une validation croisée simple, où le même repli sert à choisir le réglage et à l'évaluer, aurait probablement affiché des performances plus flatteuses mais moins fiables. La validation croisée imbriquée est plus coûteuse en temps de calcul, mais c'est le prix à payer pour affirmer qu'un résultat n'est pas un artefact de la procédure de sélection.

Le deuxième enseignement porte sur la place des modèles non linéaires. Sur ce jeu de données, les modèles non linéaires classiques (forêt aléatoire, gradient boosting, SVR) font tous moins bien qu'une régression linéaire régularisée : avec 80 échantillons pour plusieurs centaines de variables corrélées, leur flexibilité supplémentaire se traduit par de la variance plutôt que par un gain de précision. Une architecture de deep learning n'a pas été testée dans ce travail, mais le même raisonnement laisse penser qu'elle se heurterait à la même limite : rien dans la taille de ce jeu de données ne justifie a priori la complexité supplémentaire qu'elle introduirait.

Le troisième enseignement, le plus spécifique à ce jeu de données, concerne le transfert de calibration. Le résultat selon lequel la méthode la plus simple (correction pente-biais) devance la méthode de référence (Direct Standardization) sur trois propriétés sur quatre n'est pas une règle générale de la chimiométrie : il tient probablement au fait que le meilleur prétraitement de ces trois propriétés repose sur une dérivée spectrale, qui amplifierait le résidu laissé par une correction spectrale imparfaite. Cette explication est cohérente avec l'ensemble des résultats, mais n'a pas été vérifiée par un test isolant spécifiquement ce mécanisme. Elle illustre néanmoins un principe transférable : le choix de la méthode de transfert de calibration ne devrait pas se faire indépendamment du choix de prétraitement, puisque les deux semblent interagir directement.

Ce travail comporte plusieurs limites, documentées plus en détail dans le dépôt de code. La plus importante concerne le choix du prétraitement gagnant par propriété (tableau 2) : ce choix est le minimum observé parmi sept variantes testées sur le même protocole, puis réutilisé tel quel pour les analyses suivantes, ce qui introduit un biais d'optimisme classique : le gagnant a une chance non négligeable d'avoir gagné en partie par le hasard de l'échantillonnage sur seulement 80 échantillons. Corriger ce biais rigoureusement demanderait un niveau de validation croisée supplémentaire, au prix d'une perte de



puissance statistique qui n'a pas semblé justifiée à cette échelle. De même, la fenêtre des dérivées de Savitzky-Golay est fixée par convention plutôt qu'optimisée par propriété, et le Detrend retenu comme point de départ n'a pas encore été intégré à la comparaison empirique à sept variantes.

## Conclusion

Sur le jeu de données Corn, une régression PLS soigneusement validée prédit correctement la composition du maïs sur l'instrument qui a servi à la calibrer, avec des performances comparables à celles publiées par d'autres équipes sur ce même jeu de données. Cette performance s'effondre presque systématiquement dès qu'on change d'instrument, confirmant que le transfert de calibration n'est pas un raffinement optionnel mais une étape nécessaire pour tout déploiement réel. Une fois cette correction appliquée, la performance redevient exploitable pour les quatre propriétés étudiées, la méthode la plus simple testée (correction pente-biais) se révélant, de façon inattendue, au moins aussi efficace que la méthode de référence pour trois propriétés sur quatre. L'ensemble du code, des notebooks et des tests qui produisent ces résultats est disponible dans le dépôt associé à ce rapport.

## Références

- Barnes, R. J., Dhanoa, M. S., & Lister, S. J. (1989). Standard normal variate transformation and detrending of near-infrared diffuse reflectance spectra. *Applied Spectroscopy*, 43(5), 772-777.
- Catalas, O., & Tutuncu, K. (2023). Detection of protein, starch, oil, and moisture content of corn kernels using one-dimensional convolutional autoencoder and near-infrared spectroscopy. *PeerJ Computer Science*, 9, e1266.
- Eigenvector Research (1999). Corn NIR spectra for benchmarking calibration transfers. *EigenNews*, 1(3).
- Fatemi, A., Singh, V., & Kamruzzaman, M. (2022). Identification of informative spectral ranges for predicting major chemical constituents in corn using NIR spectroscopy. *Food Chemistry*, 383, 132442.
- Filzmoser, P., Liebmann, B., & Varmuza, K. (2009). Repeated double cross validation. *Journal of Chemometrics*, 23(4), 160-171.
- Geladi, P., MacDougall, D., & Martens, H. (1985). Linearization and scatter-correction for near-infrared reflectance spectra of meat. *Applied Spectroscopy*, 39(3), 491-500.
- Kennard, R. W., & Stone, L. A. (1969). Computer aided design of experiments. *Technometrics*, 11(1), 137-148.
- Roger, J.-M., Palagos, B., Bertrand, D., & Fernandez-Ahumada, E. (2011). CovSel: variable selection for highly multivariate and multi-response calibration. *Chemometrics and Intelligent Laboratory Systems*, 106(2), 216-223.
- Samuel, P. P., Chinnu, T., & Lakshmanan, M. K. (2015). Multi-parameter analysis of corn using NIR reflectance spectroscopy and chemometrics. *Materials Today: Proceedings*, 2(3), 949-953.
- Savitzky, A., & Golay, M. J. E. (1964). Smoothing and differentiation of data by simplified least squares procedures. *Analytical Chemistry*, 36(8), 1627-1639.

Varma, S., & Simon, R. (2006). Bias in error estimation when using cross-validation for model selection. *BMC Bioinformatics*, 7, 91.

Wang, Y., Veltkamp, D. J., & Kowalski, B. R. (1991). Multivariate instrument standardization. *Analytical Chemistry*, 63(23), 2750-2756.

Wold, S., Johansson, E., & Cocchi, M. (1993). PLS: partial least squares projections to latent structures. Dans H. Kubinyi (Éd.), *3D QSAR in Drug Design* (pp. 523-550). ESCOM.

Wold, S., Sjöström, M., & Eriksson, L. (2001). PLS-regression: a basic tool of chemometrics. *Chemometrics and Intelligent Laboratory Systems*, 58(2), 109-130.

Zou, H., & Hastie, T. (2005). Regularization and variable selection via the elastic net. *Journal of the Royal Statistical Society: Series B*, 67(2), 301-320.